

Proposta de Projeto (Entrega 1)

Aluno: Igor do Nascimento Alves (Matricula: 24202610466)

Disciplina: CCM-109 - TÓPICOS ESPECIAIS EM INTELIGÊNCIA ARTIFICIAL (2026.2) - UFABC

Título: Predição Tática e Coordenação Multiagente: Uma Abordagem Sequencial Profunda no Ambiente Robot Soccer SSL

Repositório: <https://github.com/IgorNascAlves/robot-soccer-ssl-tactical-prediction.git>

1. Descrição do Problema e Motivação

A orquestração de múltiplos agentes em ambientes dinâmicos (como robôs autônomos ou sistemas de enxame) baseia-se tradicionalmente em máquinas de estado. A transição para um controle descentralizado e emergente exige que os sistemas compreendam o estado global a partir de interações temporais. O problema central deste projeto é treinar um modelo de Deep Learning para modelar a dependência temporal da movimentação de um time de robôs e inferir sua tática global, utilizando o ambiente da Robot Soccer Small Size League (SSL). Esta prova de conceito é o passo fundamental para a futura aplicação de arquiteturas análogas às de Large Language Models (LLMs) na orquestração de enxames e biologia sintética.

2. Base de Dados e Pré-processamento

O conjunto de dados será construído a partir de logs oficiais de telemetria da Robot Soccer SSL, extraídos de repositórios públicos na nuvem. Os arquivos de replay, originalmente em binário (ProtoBuf), serão pré-processados e convertidos para tensores. Para capturar a evolução da jogada, os dados espaciais (coordenadas x , y e orientação θ dos aliados, adversários e bola) serão estruturados em janelas deslizantes (sliding windows) de tamanho T . Dessa forma, a rede receberá como entrada uma série temporal multivariada, onde cada amostra representa a cinemática do enxame nos últimos segundos da partida.

3. Abordagem Metodológica e Arquitetura

Para lidar com a natureza sequencial dos dados de telemetria, o projeto será desenvolvido em PyTorch, com foco nas arquiteturas avançadas abordadas na disciplina. A rede principal utilizará camadas de Redes Neurais Recorrentes, especificamente LSTMs (ou blocos de Transformers, caso a dimensionalidade temporal demande mecanismos de Attention). O modelo processará a sequência de estados do jogo para realizar uma tarefa de classificação (ex: identificar se o padrão atual é um ataque coordenado ou transição defensiva) ou de regressão (prever a posição futura dos agentes). O treinamento envolverá a otimização da função de custo (como Cross-Entropy para classificação) utilizando otimizadores avançados (ex: Adam) e técnicas de retropropagação através do tempo (BPTT).

4. Otimização, Regularização e Avaliação

Para garantir a capacidade de generalização do modelo e evitar o sobreajuste (overfitting) aos times específicos do dataset, serão aplicadas técnicas de regularização como Dropout e Early Stopping durante a fase de treinamento. O desempenho da arquitetura LSTM/Transformer será avaliado contra um conjunto de validação isolado, utilizando métricas como Loss, Acurácia e F1-Score, demonstrando o ganho prático das arquiteturas profundas na resolução de problemas complexos de coordenação.

5. Trabalhos Futuros e Integração

Como desdobramento natural desta prova de conceito, almeja-se a aplicação do modelo preditivo como o núcleo de tomada de decisão tática, substituindo lógicas codificadas manualmente tanto em ambiente de simulação quanto na transferência direta para robôs físicos (Sim-to-Real). Adicionalmente, espera-se em etapas futuras explorar Redes Adversárias Geradoras (GANs) para a geração de cenários sintéticos táticos, visando o enriquecimento do treinamento multiagente e a imitação de comportamentos complexos (GAIL).